# 📄 [Call Predict] - Documento de Arquitetura e Decisão de Machine Learning (MLSDD)

**Autor:** Ryan Ferrari (Tech Lead / Cientista de Dados)

**Data de Criação:** 10/04

## Objetivo:

Este documento tem como objetivo registrar decisões tomadas e resultados encontrados no processo de criação de um modelo de machine learning para cold calls.

## Resumo:

## 1. Exploração de métricas, problematização

Dados de Chamadas por Grupo de Conversão

| Grupo | Descrição | Total de Chamadas | Números Únicos | Duração Total (s) | Custo Total (R$) | % do Custo Total | % de Números Únicos |
|---|---|---|---|---|---|---|---|
| 0 | Convertidos (Histórico) | 82 | 13 | 3.666,33 | 66,11 | 1,06 | 0,36 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| 1 | Não Convertidos | 33.257 | 3.648 | 344.761,54 | 6.147,54 | 98,94 | 99,64 |

**Observação:** A tabela apresenta um comparativo de métricas de chamadas telefônicas entre clientes que converteram (histórico) e aqueles que não converteram.

**Principais Descobertas:**

- A grande maioria das chamadas (33.257) e dos números únicos (3.648) pertencem ao grupo de **Não Convertidos**, representando 99,64% dos números únicos e 98,94% do custo total.
- O grupo de **Convertidos (Histórico)** é significativamente menor, com apenas 82 chamadas e 13 números únicos, correspondendo a um custo total de R$ 66,11.

Quase 99% do nosso custo se dá por leads não convertidos.

A baixa taxa de conversão se dá pelo fato de serem cold calls para totais desconhecidos com intuito de marcar reunião.

Mudemos um pouco a ótica. Ao invés de buscar apenas reuniões marcadas (que dependem de fatores externos como qualidade de lista e script), vamos olhar para fatores que podemos controlar com dados: conexões reais (pessoas que atenderam e responderam a ligação)

- **Comparação de dados entre leads que conversaram com IA e não conversaram:**

| Métrica | Engajados (Target=1) | Não Engajados (Target=0) |
|---|---|---|
| **Total de Chamadas** | 3.875 | 29.464 |
| **Números Únicos** | 311 | 3.350 |
| **Duração Total (s)** | 103.350,14 | 245.077,73 |
| **Custo Total (R$)** | 1.867,09 | 4.346,56 |
| **Custo (%)** | 30,05% | 69,95% |
| **Números Únicos (%)** | 8,49% | 91,51% |

**Observações Principais:**

- **Não Engajados (Target=0)** representam a vasta maioria, com **29.464** chamadas e **91,51%** dos números únicos.
- Embora os **Não Engajados** tenham um custo total maior (R$ 4.346,56), o grupo de

**Engajados (Target=1)**, com apenas **8,49%** dos números únicos, já é responsável por **30,05%** do custo total (R$ 1.867,09).

Código: [3.Análise-supabase-calls.ipynb - Colab]

# Estratégia e modelos:

Vamos seguir a máxima de resolver o problema com o modelo mais simples.

Vamos segmentar um problema complexo em dois modelos. Cada modelo deve responder uma pergunta:

1. Lead Scoring: deve responder para quais leads vale a pena continuar ligando e quais é melhor desistir.

2. Timing predict: deve responder qual o melhor momento para ligarmos para o lead

## Output e Threshold:

Numericamente, os outputs são os mesmos. Mas significam coisas bem diferentes:

O *lead scoring* retorna um número de 0 a 1, que significa a “nota” de cada lead, ou seja, a probabilidade da ligação resultar em uma conversa real (mais de 1 minuto e meio)

O Threshold ou “nota de corte”, deve ser o mínimo possível tal que o número de falsos negativos, isto é,  quem conversaria, mas foi marcado como “desistente” seja menor que 5%. O que significa que deixamos menos de 5% de leads reais escapar. Leads abaixo da nota de corte devem ser descartados

O *Timing Predict* tem um output numérico de 0 a 1, que significa a probabilidade do lead em questão atender a ligação no momento atual.

A lógica de aplicação deste output, no entanto, é inversa à do *Lead Scoring*. Enquanto o Scoring busca o limite mínimo para *não* descartar o lead, o *Timing Predict* atua de forma contínua para encontrar o *pico* de probabilidade ao longo do dia.

**Como o *Timing Predict* funciona na prática (Grid Scoring):** Não usaremos este modelo para adivinhar o "horário perfeito" de forma abstrata. Em vez disso, usaremos a técnica de simulação. Quando precisarmos decidir se devemos ligar para um lead, o sistema irá comparar a probabilidade de atendimento no horário atual com a probabilidade nas

próximas 24 horas (excluindo o período das 23h às 6h) e decidirá qual é o melhor horário para realizar a chamada.

Para escalar isso, o sistema simula todos os horários comerciais do dia seguinte (09h, 10h, 11h, etc.) e passa todos de uma vez para o modelo. A IA retornará uma lista de probabilidades e o sistema simplesmente agendará a ligação para o horário que apresentar o maior valor (o pico).

## O Micro-fluxo da Cascata (Por Ligação)

**Gatilho (Trigger):** O sistema precisa decidir o próximo passo para o Lead "X".

- **Passo 1: O "Go/No-Go" (Lead Scoring)**
  - O sistema envia os dados do Lead X para o Modelo 1.
  - **Pergunta da IA:** *"Qual a nota desse lead agora?"*
  - **Ação:** Se a nota for **menor** que o Threshold (ex: < 0.15), o fluxo é **encerrado**. O lead recebe uma tag no CRM de "Descarte IA" ou "Frio" e vai para uma automação de reengajamento por WhatsApp/E-mail (ou morre de vez). Não se tenta ligar novamente.
  - Se a nota for **maior ou igual** ao Threshold, ele passa de fase.
- **Passo 2: O Agendamento (Timing Predict)**
  - Apenas os leads que sobreviveram ao Passo 1 chegam aqui. O sistema envia os dados do Lead X para o Modelo 2, simulando os horários do dia seguinte.
  - **Pergunta da IA:** *"Dado que vale a pena ligar, qual o horário com maior pico de probabilidade amanhã?"*
  - **Ação:** O modelo retorna o horário vencedor (ex: 16h).
- **Passo 3: Fila de Execução (Webhook / Dialer)**
  - O n8n (ou seu sistema de telefonia) agenda a retentativa de ligação exatamente para as 16h.

## Por que essa é a arquitetura definitiva?

Se você tentasse rodar o *Timing Predict* primeiro, ou os dois ao mesmo tempo, você estaria pagando custo de infraestrutura para simular 10 horários diferentes para um lead que, no fundo, já tinha nota 0 de engajamento.

A cascata protege o seu caixa duas vezes:

1. **Custo de Nuvem/API:** O Modelo 1 é um filtro rápido e barato. Ele blinda o Modelo 2 (que exige mais cálculos por causa da simulação de horários).
2. **Custo de Telefonia:** Garante que a linha só será ocupada com quem tem chance real de compra, no momento exato de maior conversão.

Como você está usando o n8n para orquestrar essas automações (conforme a base de conhecimento da MindFlow que você compartilhou antes), você pretende hospedar esses modelos XGBoost em uma API própria (como FastAPI/Python) para o n8n consultar via requisição HTTP, ou vai usar algum serviço gerenciado na nuvem (AWS SageMaker, Google Vertex)?

# XGBoost: Por Que Escolhemos Este Modelo?

## O Que é XGBoost?

XGBoost (eXtreme Gradient Boosting) é um algoritmo de machine learning que combina múltiplas árvores de decisão simples em um modelo poderoso. A ideia é simples: cada árvore aprende com os erros da anterior, corrigindo incrementalmente as previsões.

**Analogia:** Imagine 100 médicos opinando sobre um diagnóstico. O primeiro tenta e erra em 20% dos casos. O segundo estuda especificamente os erros do primeiro. O terceiro foca nos erros que sobraram. Juntos, acertam em 95%+ dos casos.

## Por Que XGBoost para Cold Calls?

**1. Dados Desbalanceados** Seus dados têm 99,64% de não-conversões e 0,36% de conversões. Algoritmos simples aprendem a sempre dizer "não" e ganham acurácia artificial. XGBoost permite ajustar pesos de classe (`scale_pos_weight = 405`), forçando o modelo a aprender os casos raros corretamente.

**2. Velocidade em Produção** Árvores de decisão são extremamente rápidas — apenas comparações lógicas, sem cálculos complexos. Latência esperada: **5-10ms por predição**. Isso permite processar centenas de leads em tempo real no n8n.

**3. Feature Importance Nativa** XGBoost explica quais variáveis importam realmente:

- Duração da última ligação: 35%
- Hora do dia: 22%
- Dias desde último contato: 18%

Você entende *por que* um lead é "quente" ou "frio". Isso é ouro para ajustar scripts e estratégia.

**4. Interpretabilidade** Diferente de redes neurais (caixa preta), XGBoost gera árvores legíveis:

```
None
SE (duração_última_ligação > 90s)

   E (dias_desde_contato < 7)

ENTÃO score_alto = True
```

Isso convence o comercial, o CTO e o board.

**5. Robustez** XGBoost lida naturalmente com dados reais: faltam valores, há outliers, padrões mudam. Não exige limpeza agressiva como redes neurais.

## Comparação Rápida

| Algoritmo | Desempenho | Velocidade | Interpretável? | Ideal para Cold Calls? |
|---|---|---|---|---|
| **XGBoost** | ⭐⭐⭐⭐⭐ | 5-10ms | ✅ Sim | ✅ **Perfeito** |
| Logistic Regression | ⭐⭐⭐ | 1ms | ✅ Sim | ❌ Muito simples |
| Random Forest | ⭐⭐⭐⭐ | 20-30ms | ⚠️ Caixa preta | ⚠️ Bom, mas lento |
| Redes Neurais | ⭐⭐⭐⭐⭐ | 50ms+ | ❌ Caixa preta | ❌ Overhead desnecessário |

XGBoost é o ponto ótimo: máxima eficácia com máxima velocidade e interpretabilidade.

## Como Funciona Na Cascata

**Lead Scoring (Modelo 1 - XGBoost):**

- Entrada: Features do lead (duração, tentativas, hora, dias...)
- Output: Número de 0 a 1 (probabilidade de engajamento)
- Ação: Se score < 0.15 → descartar. Senão → ir para Timing Predict

**Timing Predict (Modelo 2 - XGBoost):**

- Entrada: Dados do lead + simula cada hora do dia seguinte
- Output: Horário com maior probabilidade de atendimento
- Ação: Agenda ligação exatamente naquele horário

**Por que dois modelos?** Porque rodar Timing Predict (que exige 10 simulações) em leads com score 0 seria desperdício de computação e dinheiro. O Model 1 filtra, o Model 2 otimiza.

---

# Feature Engineering e ETL:

Para que o modelo funcione de maneira correta, devemos tratar os dados para que ele receba todas as informações necessárias para a predição, assim como devemos garantir que ele não receba nenhuma informação desnecessária que o atrapalhe ou se torne uma muleta/vício.

## 1. Lead Scoring:

**Colunas de Dados para o Processo de Machine Learning**

As seguintes colunas são essenciais para o modelo de Machine Learning, agrupadas por categoria:

**Informações Geográficas:**

- `ddd`: Código de Discagem Direta à Distância (identifica a cidade).
- `Regiao`: Estado (e.g., SP, MA, PI, SC).

**Métricas de Tentativas:**

- `n_tentativas_anteriores`: Número total de tentativas de contato prévias.
- `horas_desde_primeiro_contato`: Tempo decorrido (em horas) desde o primeiro contato registrado.

**Contagem de Razões de Disconexão/Status (Anteriores):**

- `n_voicemail_reached_anteriores`: Número de vezes que uma caixa postal foi alcançada.
- `n_dial_no_answer_anteriores`: Número de chamadas sem resposta.
- `n_inactivity_anteriores`: Número de vezes com inatividade detectada.
- `N_invalid_destination_anteriores`: Número de destinos inválidos.
- `N_user_hangup_anteriores`: Número de desligamentos iniciados pelo usuário.
- `N_user_declined_anteriores`: Número de vezes que o usuário recusou a chamada.
- `N_telephony_provider_permission_denied_anteriores`: Número de vezes que o provedor de telefonia negou a permissão.
- `N_dial_busy_anteriores`: Número de sinais de ocupado (`busy`).
- `N_telephony_provider_unavailable_anteriores`: Número de vezes que o provedor de telefonia estava indisponível.
- `N_agent_hangup_anteriores`: Número de desligamentos iniciados pelo agente.
- `N_error_asr_anteriores`: Número de erros de Reconhecimento Automático de

Fala (ASR).
- `N_error_retell_anteriores`: Número de erros de *retell*.
- `N_dial_failed_anteriores`: Número de falhas na discagem.
- `N_max_duration_reached_anteriores`: Número de vezes que a duração máxima da chamada foi atingida.
- `N_ivr_reached_anteriores`: Número de vezes que o IVR (Interactive Voice Response) foi alcançado.

**Status da Última Interação:**

- `ultima_disconnection_reason`: Motivo da última desconexão.

## 2. Timing Predict:

considerações gerais:

- `ddd`
- `hora_contato` (horário para predição)
- `dia_semana` (1, para segunda. 7 para domingo)
- densidade_tentativas
- pressao_recente
- hora_ultimo_contato

### 1. `densidade_tentativas` (A Fadiga Crônica)

**O que é (Conceito):** Essa métrica mede a **saturação geral** do lead desde que ele entrou na sua base de dados. Ela responde à pergunta: *"No panorama geral, nós estamos bombardeando essa pessoa com ligações ou estamos indo devagar?"* Leads com densidade muito alta geralmente já bloquearam o seu número mentalmente ou no próprio aparelho.

**Como é calculada (Matemática):** Ela divide o total de ligações que já fizemos pelo tempo de vida total do lead na base.

> **Cálculo:** `n_tentativas_anteriores / (horas_desde_primeiro_contato + 1)`

- **O numerador:** É o número absoluto de vezes que já tentamos falar com ele.

- **O denominador:** É o número de horas que se passaram desde a *primeira vez* que discamos para esse número.
- **Por que o + 1?** É um fator de suavização matemática. Se for o primeiro dia de vida do lead (0 horas passadas), tentar dividir por zero faria o código "quebrar" (retornando infinito ou erro). O +1 resolve isso elegantemente.

**Exemplo Prático:**

- Se tentamos ligar 10 vezes em 10 horas de vida do lead = Densidade de **1.0** (Altíssima saturação, 1 ligação por hora).
- Se tentamos ligar as mesmas 10 vezes, mas ao longo de 500 horas (aprox. 20 dias) = Densidade de **0.02** (Baixa saturação, lead "descansado").

---

## 2. pressao_recente (A Fadiga Aguda / Fator de Esfriamento)

**O que é (Conceito):** Essa métrica mede a **agressividade de curto prazo**. Ela ignora quando o lead entrou na base e foca apenas no "intervalo de respiro" desde o último incômodo. Ela responde à pergunta: *"Não importa o passado distante; nós estamos enchendo o saco dele AGORA?"* Essa é a métrica que diz ao modelo que o cliente precisa "esfriar" antes de tentarmos novamente.

**Como é calculada (Matemática):** Ela divide o total de ligações que já fizemos pelo tempo que se passou desde o *último* toque do telefone.

> **Cálculo:** `n_tentativas_anteriores / (horas_desde_ultimo_contato + 1)`

- **O numerador:** O total de tentativas acumuladas.
- **O denominador:** O número de horas desde a **última** vez que a nossa IA tentou ligar.

**Exemplo Prático (O Poder do Esfriamento):** Imagine um lead para o qual já ligamos 15 vezes (um número altíssimo de tentativas).

- **Cenário A (Sufocando):** A última ligação foi há apenas 1 hora. Cálculo: `15 / (1 + 1)` = Pressão Recente de **7.5**. (O modelo vê esse número gigante e entende: *"Bloqueie a ligação agora, ele vai rejeitar na hora"*).

- **Cenário B (Esfriado):** A última ligação foi há 150 horas (cerca de 6 dias atrás). Cálculo: 15 / (150 + 1) = Pressão Recente de **0.09**. (Apesar de ter 15 tentativas no histórico, o modelo entende: *"Ele teve muito tempo para esfriar e esquecer de nós. É seguro tentar uma nova abordagem agora"*).

### Resumo da diferença:

A **Densidade de Tentativas** olha para o seu relacionamento histórico completo com o lead, enquanto a **Pressão Recente** olha para a urgência e o risco de irritá-lo *hoje*. Usar as duas juntas é o que dá ao XGBoost a capacidade humana de ter "bom senso" antes de agendar uma chamada.

Códigos: Lead_Scoring_ETL.ipynb - Colab, TP_ETL.ipynb - Colab

# Resultados:

Após treinar os modelos, encontramos os seguintes dados:

## Lead Scoring:

**Importância de cada feature:**

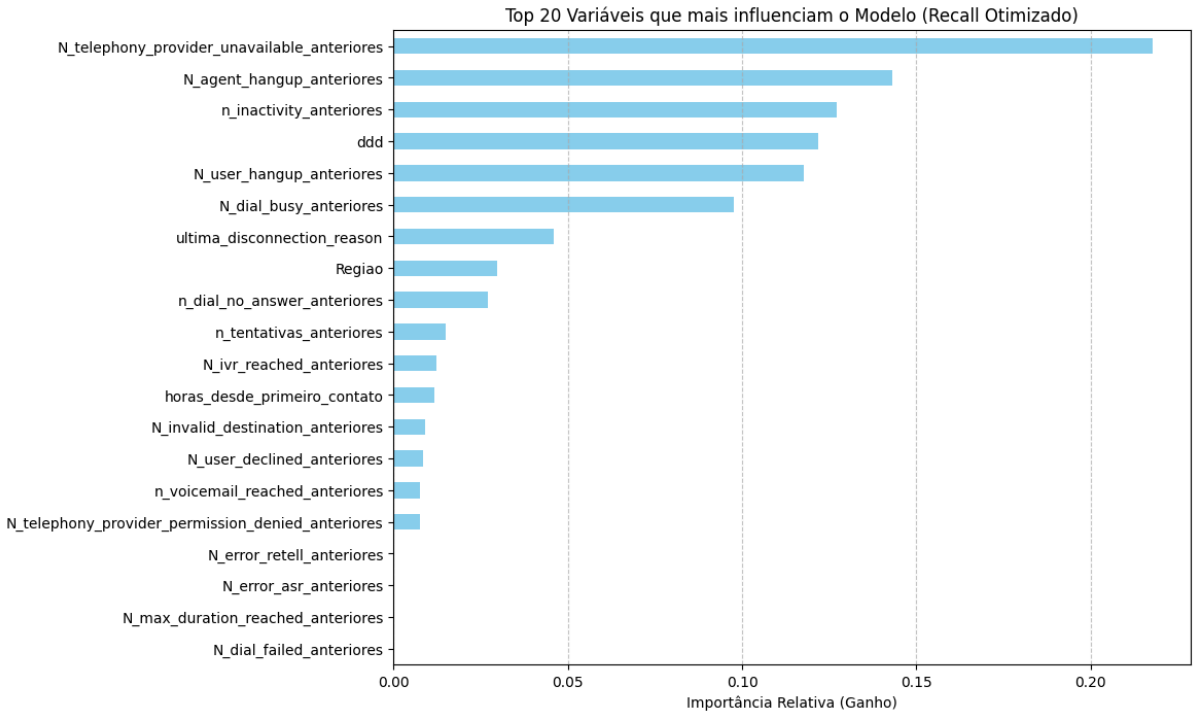


**Threshold Aplicado:**

Fórmula: FN/ (FN+VN)

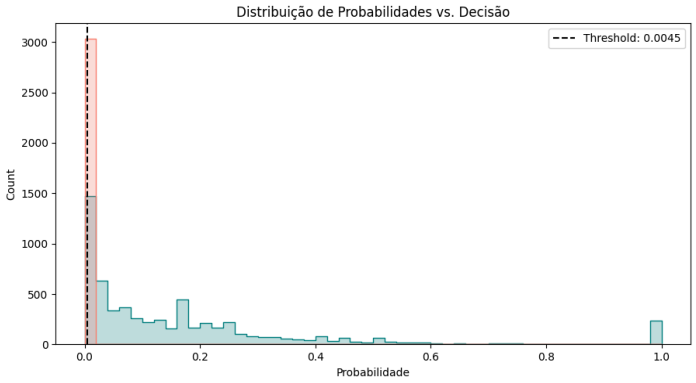


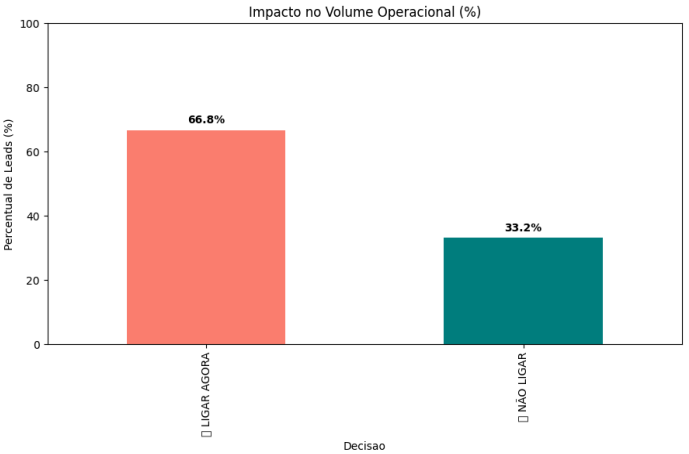


--- RESUMO COM THRESHOLD DE 0.0045 ---
Total de Leads: 9136
Leads para LIGAR: 6102 (66.8%)
Leads filtrados (NÃO LIGAR): 3034 (33.2%)

Falsos Negativos entre os leads filtrados (NÃO LIGAR): 1
Porcentagem de Falsos Negativos entre os leads filtrados (NÃO LIGAR): 0.03%

Mesmo aplicando um threshold muito mais restrito que o idealizado, que previa 5% de falsos negativos enquanto o atual tem 0.03% de falsos negativos, mantivemos uma economia (em número bruto de leads) de 33,5%

**Métricas:**

| Métrica | Classe 0 | Classe 1 | Média Ponderada |
|---|---|---|---|
| **Precisão** | 1.00 | 0.58 | 0.98 |
| **Recall (Sensibilidade)** | 0.98 | 0.91 | 0.97 |
| **F1-Score** | 0.99 | 0.71 | 0.98 |

- **Classe 0 (Majoritária):** O modelo é quase perfeito na identificação da classe 0, com 100% de precisão e 98% de *recall*.
- **Classe 1 (Minoritária):** Embora a precisão seja de 58%, o *recall* de 91% indica que o modelo é altamente eficaz em detectar a maioria das ocorrências da classe minoritária. O *F1-score* de 0.71 reflete o bom equilíbrio entre precisão e *recall* para esta classe, apesar do desequilíbrio do conjunto de dados.

Matriz de Confusão (Valores Absolutos)

A matriz detalha o número de previsões corretas e incorretas:

| Real/Predito | Predito 0 | Predito 1 | Total Real |
|---|---|---|---|
| **Real 0** | 43.112 (Verdadeiro Negativo) | 1.010 (Falso Positivo) | 44.122 |
| **Real 1** | 134 (Falso Negativo) | 1.420 (Verdadeiro Positivo) | 1.554 |

Sumário e Desempenho Global

- **Acurácia Global:** 0.97

- **Média Macro:** Precisão (0.79), Recall (0.95), F1-Score (0.85)
- **ROC-AUC Score:** 0.9892 (Indicando excelente capacidade de distinção entre as classes)

Códigos: Lead_scoring_Training_ML.ipynb - Colab, ML_LS_Métricas.ipynb - Colab

## Timing Predict:

**Importância de cada feature:**

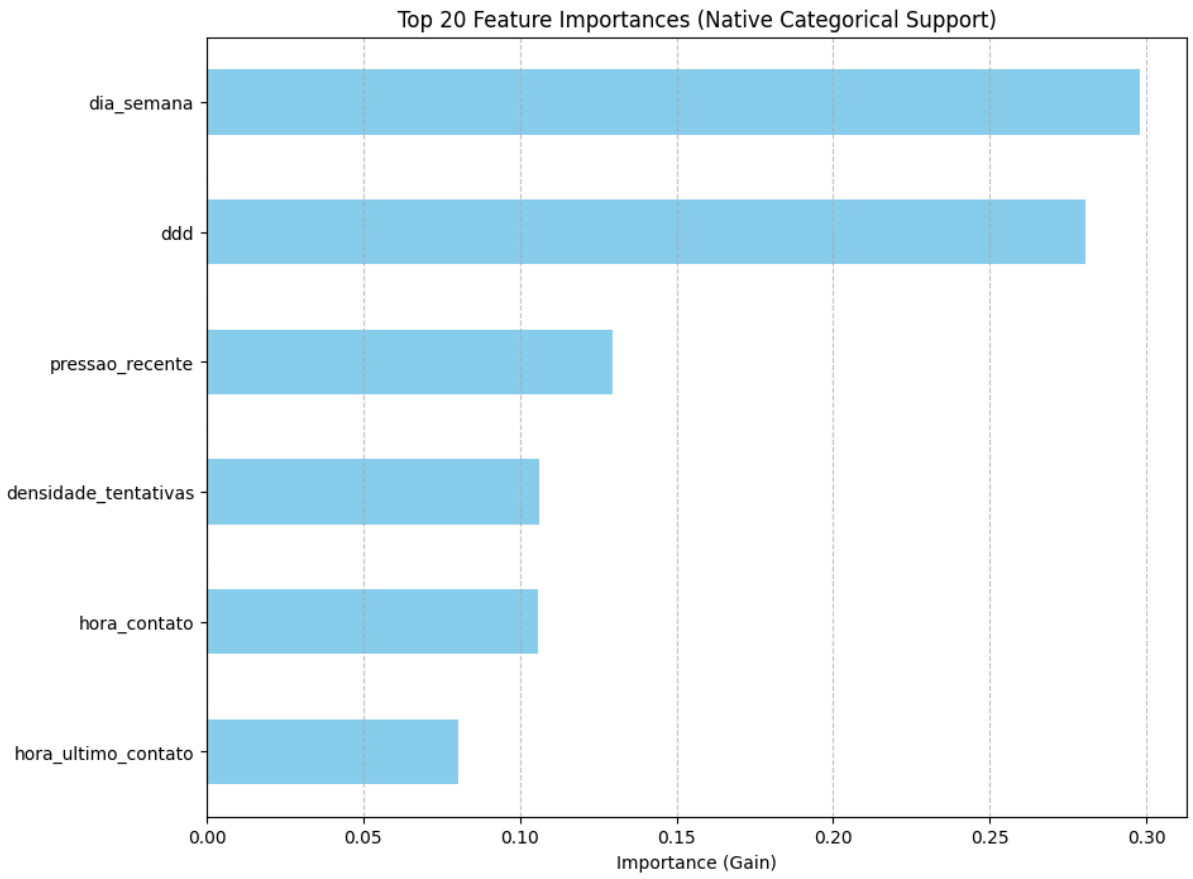
Top 20 Feature Importances (Native Categorical Support)
dia_semana
ddd
pressao_recente
densidade_tentativas
hora_contato
hora_ultimo_contato
0.00
0.05
0.10
0.15
0.20
0.25
0.30
Importance (Gain)

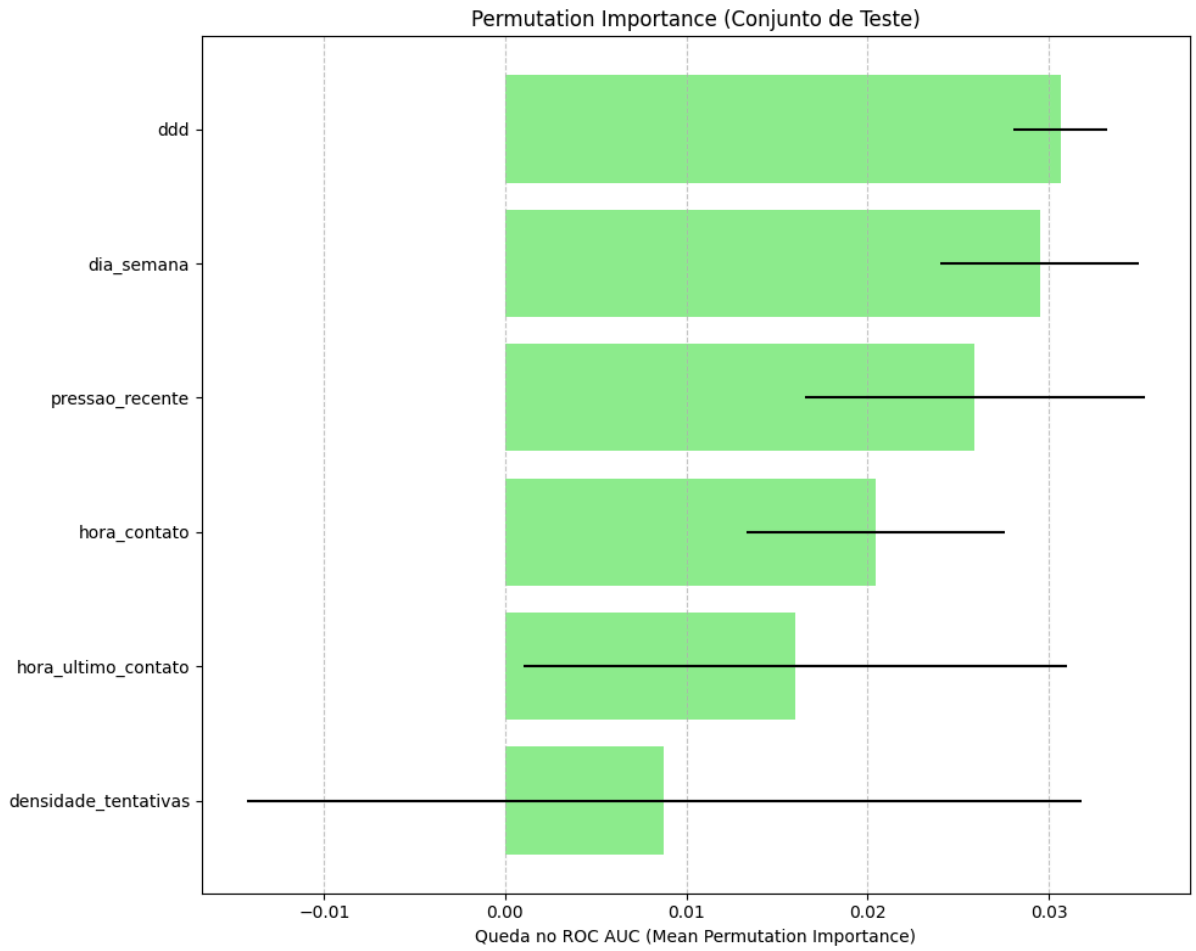


## 📊 O Conceito de Elasticidade Probabilística Temporal

Diferente de modelos de classificação tradicionais que buscam responder *"quais variáveis aumentam a chance bruta de venda?"*, o nosso Estágio 2 de *Timing Predict* foi construído em cima do conceito de **Elasticidade Probabilística Temporal**.

A elasticidade mede o quanto a probabilidade de um lead atender o telefone **flutua (varia)** ao longo das 24 horas de um dia. Matematicamente, ela é a amplitude (Delta) entre o pico máximo de probabilidade e o vale mínimo dentro de uma janela de simulação diária.

A implementação dessa análise trouxe três validações cruciais para a nossa arquitetura:

- **Justificativa do Motor de Simulação (Next Best Action):** Se a probabilidade fosse estática (inelástica), não haveria necessidade de simular o relógio; ligaríamos a qualquer momento. A análise de elasticidade provou que a probabilidade sofre variações drásticas dependendo da hora. Portanto, varrer o futuro simulando as próximas 24 horas é a única forma matemática de garantir que a ligação ocorrerá no pico exato de engajamento daquele lead.
- **A Quebra do "Melhor Horário Universal":** A elasticidade revelou que a variável `ddd` responde por quase metade de toda a flutuação do modelo. Isso derrubou o mito operacional de que existe um "melhor horário para ligar" global. A sensibilidade

ao relógio é ditada pela geografia e pela rotina local. O que é o horário nobre para um lead em São Paulo (DDD 11) pode ter conversão nula para um lead no interior do Paraná (DDD 46).

- **O Efeito Congelante da Fadiga:** Descobrimos que o histórico de contato altera a elasticidade. Leads "descansados" são altamente elásticos (possuem picos claros de oportunidade ao longo do dia). Por outro lado, leads com alta `densidade_tentativas` e `pressao_recente` tornam-se inelásticos: a probabilidade de atendimento é achatada para próximo de zero o dia inteiro, sinalizando para a IA que o contato deve ser suspenso temporariamente.

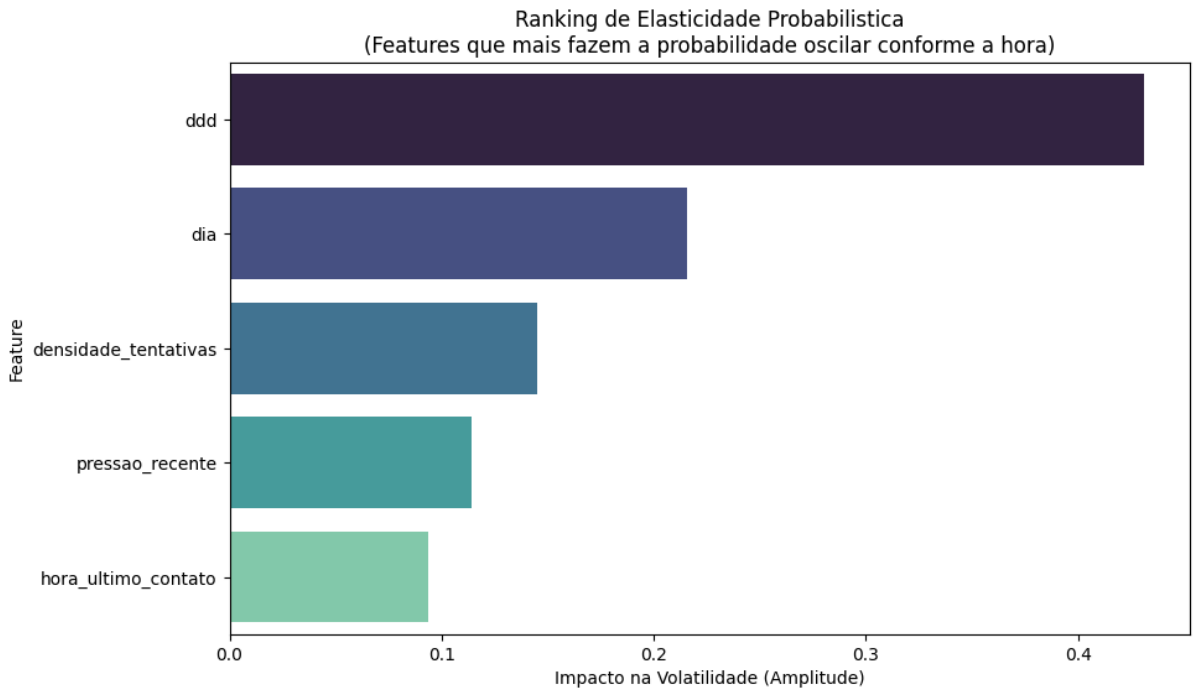


**Métricas:**

Uma das maiores preocupações na construção desse modelo, foi em não “viciar” ele a apontar apenas um horário como o melhor para todos os leads, pois isso geraria um “engasgamento” no provedor de telefonia, fazendo com que tivéssemos um número exorbitante de ligações em um dado horário.

O gráfico abaixo mostra exatamente como o horário se interligou ao ddd, criando uma dependência alta entre as features, indicando que o modelo não está olhando cegamente para o horário, mas sim o comparando com outras features.

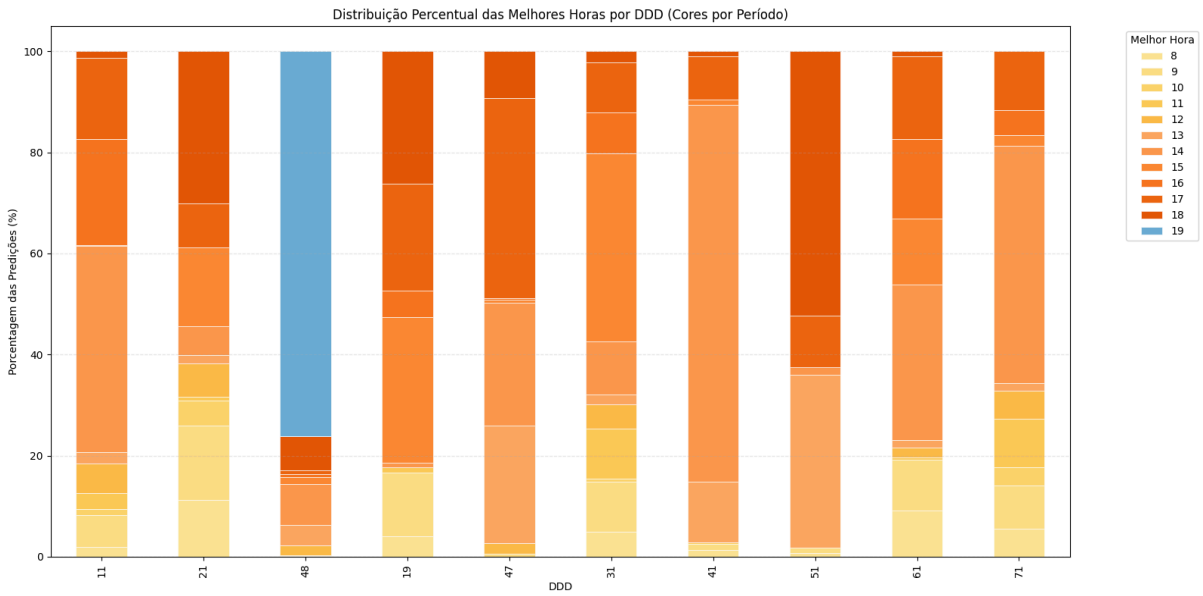


## RELATÓRIO DE AVALIAÇÃO DO MODELO DE CLASSIFICAÇÃO

### Resumo dos Resultados de Classificação

O modelo de Machine Learning demonstrou uma **acurácia geral muito alta (0.99)**. No entanto, a análise detalhada dos resultados revela uma disparidade significativa no desempenho entre as classes.

**Métricas de Desempenho (Classes):**

| Classe | Precisão | Recall | F1-Score | Suporte |
|---|---|---|---|---|
| **0** | 1.00 | 1.00 | 1.00 | 9088 |
| **1** | 0.07 | 0.12 | 0.08 | 26 |

**Média Ponderada:** Precisão (0.99), Recall (0.99), F1-Score (0.99)
**Média Macro:** Precisão (0.53), Recall (0.56), F1-Score (0.54)
**Total de Amostras:** 9114

**Análise da Matriz de Confusão:**

| Predição \ Real | Classe 0 (Negativo) | Classe 1 (Positivo) |
|---|---|---|
| **Classe 0** | Verdadeiros Negativos: 9045 | Falsos Negativos (Erro Tipo II): 23 |
| **Classe 1** | Falsos Positivos (Erro Tipo I): 43 | Verdadeiros Positivos: 3 |

**Observações Chave:**

1. **Dominância da Classe 0:** A classe majoritária (0) foi classificada com perfeição (Precisão, Recall e F1-Score de 1.00), representando 9088 das 9114 amostras.
2. **Desempenho Fraco na Classe 1:** A classe minoritária (1), com apenas 26 amostras, apresenta um desempenho extremamente baixo:
    - **Baixa Precisão (0.07):** Apenas 7% das previsões como "1" estavam corretas.
    - **Baixo Recall (0.12):** O modelo identificou corretamente apenas 12% dos casos reais da classe "1" (apenas 3 dos 26 casos).
3. **Matriz de Confusão Detalhada:** A matriz confirma que o modelo errou 23 vezes ao classificar um caso positivo (1) como negativo (0) e 43 vezes ao classificar um caso negativo (0) como positivo (1).

**Conclusão:** Embora a acurácia geral seja alta devido ao grande volume da Classe 0, o modelo tem uma **baixa capacidade de identificar a Classe 1**, indicando um problema de generalização ou um viés significativo devido ao desequilíbrio das classes.

As métricas iniciais podem sugerir que o modelo é um fracasso, especialmente considerando que uma versão anterior apresentava maior acurácia e precisão na previsão de probabilidade. No entanto, a decisão de manter o modelo atual se baseia no nosso objetivo principal: não buscamos o modelo mais robusto para prever com exatidão a probabilidade de atendimento em um horário específico, mas sim o modelo mais simples e eficiente capaz de responder à pergunta fundamental: "Em qual horário devo ligar?".

Por isso, o foco mudou para a análise de elasticidade probabilística. Deixamos de priorizar variáveis que melhor definem a precisão da probabilidade e passamos a focar naquelas que são mais importantes para indicar o horário mais provável. Essa mudança nos permitiu manter a versão do modelo que é mais eficaz no cumprimento de sua função prática, mesmo que suas métricas de precisão absoluta sejam inferiores à versão anterior.

**Códigos:** Timing_predict_Training_ML.ipynb - Colab, ML_LS_Métricas.ipynb - Colab

# Para Devs:

## 1. Data Storage: Estrutura das Bases de Dados

Para garantir a separação de responsabilidades entre a execução da infraestrutura e o histórico de predições da IA, o sistema utiliza duas tabelas distintas no Supabase. O motor de decisão não armazena os resultados finais das chamadas (que ocorrem noutro sistema pós-execução), focando-se estritamente na rastreabilidade do *workflow* e nas inferências matemáticas.

**Tabela A: `model_data` (Rastreabilidade de Inteligência)**

Esta tabela é o coração do MLOps. Regista exclusivamente a versão do modelo utilizado e as decisões matemáticas tomadas, permitindo auditorias e o cálculo do *threshold* em retreinos futuros.

**Estrutura Base e Rastreamento:**

- `id` (UUID): Identificador único do registo.
- `created_at` (Timestamp): Data e hora da inferência.
- `model_id` (String): Identificador único da arquitetura do modelo.
- `model_name` (String): Nome descritivo (ex: "XGBoost_Vendas_B2B").
- `model_version` (String): Versão do modelo (crucial para testes A/B e *rollbacks*).
- `to_number` (String): Número do lead avaliado.
- `agent_id` (String): Identificador do agente/campanha de destino.

**Resultados do Modelo 1 (Lead Scoring):**

- `ls_probabilidade` (Float): O valor bruto devolvido pelo modelo (ex: 0.0084).
- `ls_decisao` (String): A ação tomada pelo sistema (`LIGAR` ou `DESCARTAR`), baseada no *threshold*.

**Resultados do Modelo 2 (Timing Predict):**

- `tp_horario_escolhido` (Integer): A hora do dia determinada como o pico de probabilidade (ex: 16).
- `tp_probabilidade_pico` (Float): A probabilidade calculada para essa hora específica.

**Controlo de Viés e Aleatoriedade (Grupo de Controlo):**

- `is_exploration` (Boolean): Marcação obrigatória. `TRUE` se o lead caiu na taxa de 5% de aleatoriedade (bypassing as regras da IA e indo direto para a chamada), e `FALSE` se a ação foi totalmente ditada pela IA (*Exploitation*).

**Tabela B: `workflow_executions` (Orquestração e Logs)**

Tabela partilhada entre os diversos serviços da empresa para registar o ciclo de vida sistémico de um *workflow* (entrada, processamento e saída).

**Estrutura Base e Controle de Estado:**

- `id` (UUID): Identificador único da execução do *workflow* (gerado automaticamente).
- `workflow_name` (String): Nome descritivo do processo que está a ser executado (ex: "Processamento_IA_Ligacao").
- `status` (String): Estado atual da execução da tarefa. Inicia por norma como `PENDING` e transita para `COMPLETED` ou `FAILED`.
- `input_data` (JSONB): Carga de dados inicial (*payload*) recebida no momento em que o gatilho foi acionado (ex: `telefone` e `agent_id`).

- `output_data` (JSONB): Carga de dados final devolvida no final da execução, contendo as decisões tomadas para serem passadas ao próximo serviço.
- `error_details` (Text): Registo detalhado do erro (*stack trace* ou mensagem), preenchido automaticamente caso a execução falhe.
- `started_at` (Timestamp): Data e hora exata em que o processamento real da tarefa começou.
- `completed_at` (Timestamp): Data e hora exata em que o processamento terminou (com sucesso ou falha).
- `created_at` (Timestamp): Data e hora em que o registo foi criado na base de dados.
- `updated_at` (Timestamp): Data e hora da última alteração ao registo (atualizado automaticamente pelo sistema sempre que o `status` muda).

---

*Nota arquitetural: Esta tabela possui índices de performance nas colunas `workflow_name`, `status` e `created_at` para garantir buscas rápidas, mesmo com um elevado volume de execuções simultâneas, e um gatilho (trigger) na base de dados que atualiza a coluna `updated_at` de forma autónoma.*

**Guião do Cientista/Engenheiro de Dados:**

1. **Extração do Grupo de Controlo:** Isolar os registos onde `is_exploration = TRUE`. Avaliar se os leads que o modelo pontuou com notas baixas continuam a não converter. Se começarem a converter, a IA precisa de aprender o novo padrão.
2. **Preparação com Sample Weights:** Ao injetar os dados no XGBoost, os dados marcados como `is_exploration = TRUE` devem receber um "peso" estatístico distinto para não corromperem as certezas do modelo sobre os horários e rejeições reais.
3. **Divisão Temporal Obrigatória (Temporal Split):** O `train_test_split` aleatório está **proibido**. A validação do novo modelo deve usar sempre os últimos 20% cronológicos da base de dados como Teste, garantindo que não existe vazamento de dados (*Data Leakage*) do mesmo contacto.
4. **Auditoria de Feature Importance:** Antes de validar o modelo, gerar o gráfico de importância. Se uma nova variável surgir com mais de 50% de peso, a equipa deve investigar ativamente um possível vazamento de dados do futuro (ex: dados preenchidos pós-chamada).

**Processo de Deploy (Code Review):** Nenhum modelo (ficheiro `.json`) pode ser colocado em produção diretamente. A atualização exige a criação de um *Pull Request* (PR) contendo:

- O novo ficheiro do modelo.
- Um relatório (.pdf ou markdown) anexado, demonstrando a nova Matriz de Confusão, a curva ROC-AUC e o *Threshold* ideal sugerido.
- Aprovação obrigatória (*Code Review*) por um *Tech Lead* ou colega engenheiro antes de efetuar o *merge* para a *branch* principal da API (FastAPI).

## Model Workflow: Arquitetura do Fluxo de Execução

O *workflow* foi desenhado para ser resiliente, assíncrono e proteger a integridade dos dados originais. Ao invés de mutar o estado das variáveis, o sistema cria cópias tratadas especificamente para a "linguagem" de cada modelo.

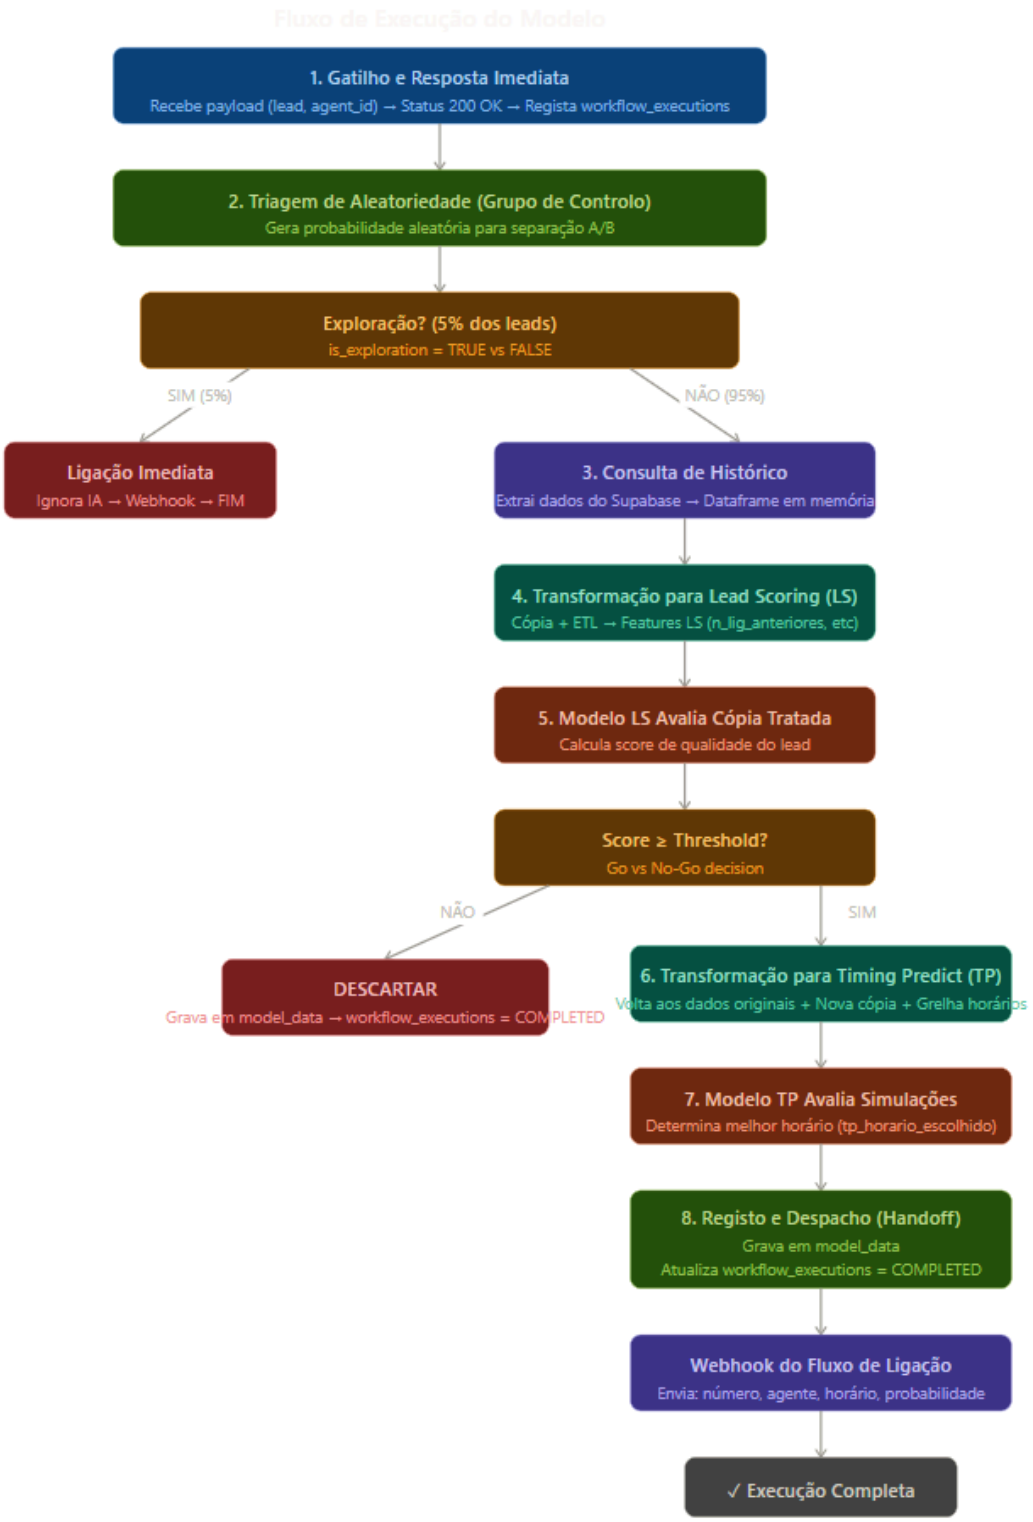

**O Fluxo Passo-a-Passo:**

1. **Gatilho e Resposta Imediata:** O servidor recebe o *payload* (ex: via n8n) com o número do lead e `agent_id`. Imediatamente, devolve um *Status 200 OK* para libertar o serviço de origem de qualquer *timeout*. O registo é iniciado na tabela `workflow_executions` com status `PENDING`.
2. **Triagem de Aleatoriedade (Grupo de Controlo):** O algoritmo gera uma probabilidade aleatória. Para 5% dos leads (`is_exploration = TRUE`), todo o bloco de Inteligência Artificial é ignorado. Estes leads são encaminhados imediatamente para a ligação e o *workflow* é encerrado.
3. **Consulta de Histórico:** Para os 95% restantes (`is_exploration = FALSE`), o sistema consulta o Supabase para extrair todo o histórico de interações associadas àquele número, guardando o *dataframe* bruto em memória.
4. **Transformação para Lead Scoring (LS):** * O sistema cria uma **cópia estrita** dos dados originais.
    - Aplica o ETL formatando a cópia para a estrutura de *features* exigida pelo Modelo LS (ex: `n_lig_anteriores`, colunas de contagem, etc.).
5. **Decisão de Filtragem (Go/No-Go):** O Modelo LS avalia a cópia tratada.
    - Se a nota for abaixo do *threshold*: A decisão é `DESCARTAR`. Os dados são gravados na tabela `model_data` e a execução na `workflow_executions` é atualizada para `COMPLETED`. Fim do ciclo.
    - Se a nota for igual ou superior: A decisão é `CONTINUAR`.
6. **Transformação para Timing Predict (TP):**
    - O sistema volta aos dados originais intocados em memória e gera uma **nova cópia**.
    - Esta cópia é formatada para o Modelo TP, recebendo as variáveis adicionais necessárias (ex: simulação de grelha de horários `hora_tentativa = [7..22]`).
7. **Determinação do Pico de Conversão:** O Modelo TP avalia as simulações e determina o melhor horário (`tp_horario_escolhido`) e a sua probabilidade (`tp_probabilidade_pico`).
8. **Registo e Despacho (Handoff):** * Os dados da predição são gravados na `model_data`.
    - A tabela `workflow_executions` é atualizada com o `output_data` final e o status `COMPLETED`.
    - O servidor dispara uma requisição HTTP para o *webhook* do fluxo de ligação, enviando as coordenadas exatas: o número, o agente e a ordem/horário para a chamada ocorrer.

---

# Próximos Passos

Para o melhoramento constante dos modelos, vamos seguir uma estratégia de hipótese + refutação, onde levantamos hipóteses acerca dos dados e como melhorar a performance dos modelos, depois buscamos maneiras de refutá-los. Enquanto uma hipótese não é refutada, é tratada como verdadeira.
Essa abordagem exige uma validação forte para cada hipótese levantada, sendo importante tentativas de refutá-la. Cada hipótese deve ter um motivo para ser levantada e uma prova em questão.

Vejamos essa abordagem aplicada com um exemplo:

**Hipótese:** um modelo de timing predict com a feature “horas desde o último contato”, deve performar melhor.
Motivo: Com o modelo atual, só sabemos as horas desde o primeiro contato. Com a informação de quanto tempo se deu desde o pultimo contato, o modelo deve ser capaz de prever situações como: Se ligarmos 3 vezes em menos de 5 minutos, a probabilidade de atender diminui.
refutação: Se o modelo não tiver pelo menos 1% a mais de precisão com uma feature importance relevante para nova feature, não vale a pena a implementação.

Nova Feature Importance:

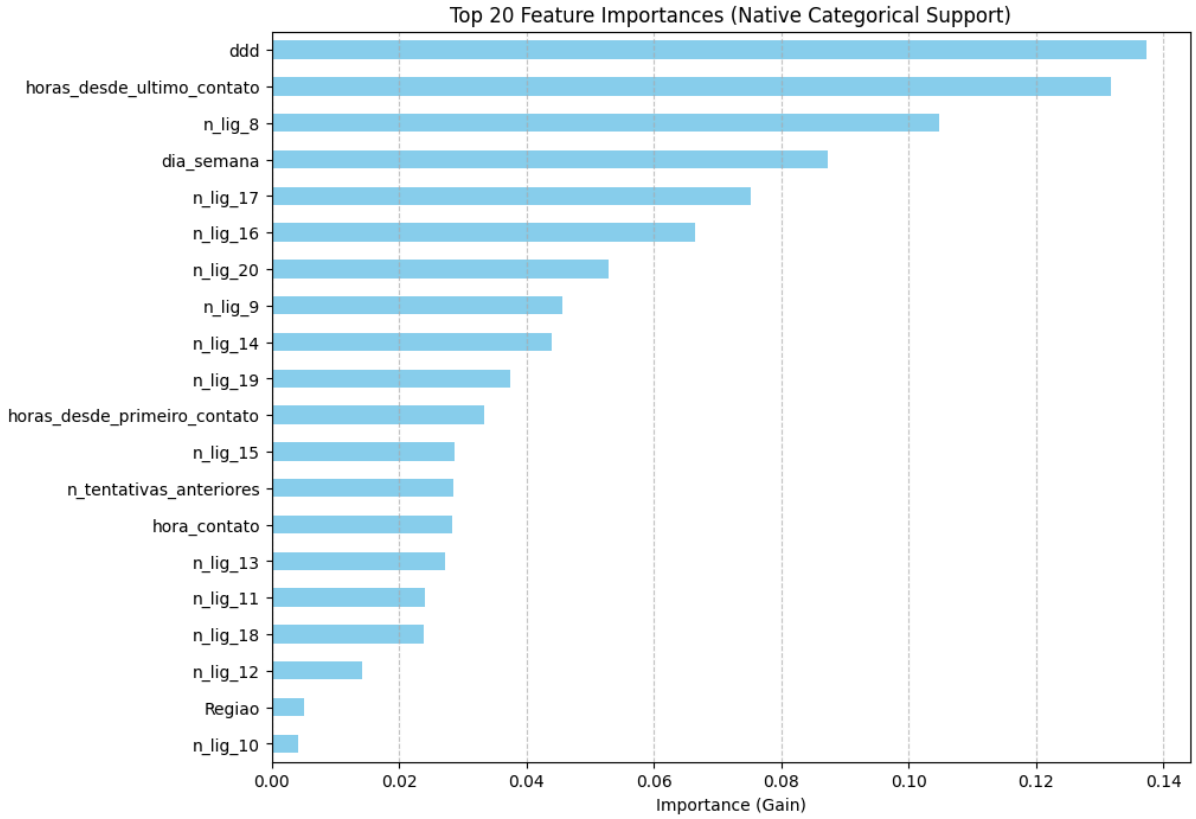

Como podemos ver, a nova feature é a segunda mais importante para a decisão do modelo.

Mas a precisão aumentou, ou é mais uma feature que faz o modelo errar mais?

**Exemplo de Aplicação Utilizando o Melhor Limiar (Threshold)**

O relatório de classificação a seguir demonstra o desempenho do modelo com o *threshold* otimizado:

| Classe | Precision | Recall | F1-Score | Suporte |
|---|---|---|---|---|
| **0** | 1.00 | 0.99 | 0.99 | 7878 |
| **1** | 0.05 | 0.20 | 0.08 | 25 |
| **Acurácia** | | | 0.99 | 7903 |
| **Média Macro** | 0.52 | 0.59 | 0.54 | 7903 |
| **Média Ponderada** | 0.99 | 0.99 | 0.99 | 7903 |

**Análise:**

- A **Acurácia** geral do modelo é de 0.99.
- Para a **Classe 0** (majoritária), as métricas são altas (*Precision* 1.00, *Recall* 0.99, *F1-Score* 0.99).
- Para a **Classe 1** (minoritária), as métricas são baixas, indicando um desafio na identificação: *Precision* de 0.05 e *Recall* de 0.20.
- As médias (**Macro** e **Ponderada**) refletem a alta desproporção entre as classes (Suporte de 7878 vs 25).

**Matriz de Confusão (Dados do Modelo)**

| Valor Predito | Real: 0 (Negativo) | Real: 1 (Positivo) |
|---|---|---|

| | | |
|---|---|---|
| **Predito: 0 (Negativo)** | 7832 (Verdadeiros Negativos) | 23 (Falsos Negativos - Erro Tipo II) |
| **Predito: 1 (Positivo)** | 46 (Falsos Positivos - Erro Tipo I) | 2 (Verdadeiros Positivos) |

### 📊 1. Análise Comparativa Direta: O Desempenho Crítico do Modelo 2

Em um cenário de eventos raros, como ligações de vendas bem-sucedidas, o foco essencial é em **Recall** (capturar o máximo de vendas) e **Precisão** (otimizar o custo evitando chamadas inúteis). A tabela a seguir expõe a disparidade drástica entre os modelos:

| Métrica (Classe 1 - Sucesso) | Modelo 1 (Campeão) | Modelo 2 (Nova Feature) | Análise de Impacto |
|---|---|---|---|
| **Precisão** | **34.0%** | **5.0%** | Queda abrupta. O Modelo 2 falha em 95% das tentativas de previsão de sucesso. |
| **Recall (Cobertura)** | **82.0%** | **8.0% a 20%** | **M1:** Resgatou 80 vendas de 97. **M2:** Resgatou apenas 2 vendas de 25. O desempenho é significativamente inferior. |
| **Falsos Positivos (Custo)** | 156 ligações inúteis | 46 ligações inúteis | Embora o M2 gere menos Falsos Positivos, isso se deve à sua baixa cobertura, ou seja, ele praticamente parou de tentar prever sucessos. |

*(Observação: O M2 reporta um Recall de 20% no texto. Contudo, a matriz de confusão indica apenas 2 Acertos Verdadeiros (TP) e 23 Falsos Negativos (FN), o que resulta em um Recall matemático de $2 / 25 = 8%$. Em ambas as estimativas, o desempenho é inaceitável frente aos 82% do M1).*